A análise de imagens de punção aspirativa por agulha fina produz medidas quantitativas da forma dos núcleos celulares. Este trabalho investiga se oito dessas medidas permitem distinguir padrões benignos e malignos de maneira reproduzível.

OBJETIVO

Construir um classificador binário, comparar algoritmos, avaliar o modelo em dados separados e disponibilizar a Regressão Logística em uma interface web com validação de entradas.

Por que Regressão Logística?

- ✓ **Probabilidade** produz uma estimativa entre 0 e 1, fácil de comunicar.
- ✓ **Interpretabilidade** permite inspecionar o sinal dos coeficientes padronizados.
- ✓ **Baseline sólido** é simples, rápido e adequado à classificação binária.
- ✓ **Implantação** o pipeline salvo pode ser carregado diretamente pela API.

Responsabilidade: o sistema é exclusivamente educacional, não foi validado clinicamente e não substitui avaliação, exame ou diagnóstico realizado por profissional de saúde.

Breast Cancer Wisconsin (Diagnostic)

Fonte: UCI Machine Learning Repository, Wolberg et al. (1993), DOI 10.24432/C5DW2B. A cópia do scikit-learn foi usada para reprodutibilidade.

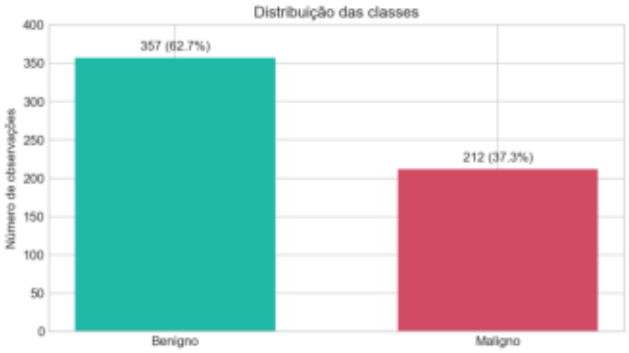
569	30	357	212
registros	atributos originais	benignos	malignos

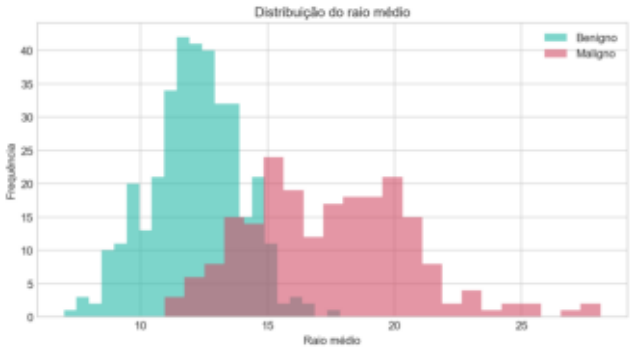
Atributos usados pelo modelo

- **Raio, perímetro e área** — medidas de tamanho do núcleo.
- **Textura** — variação dos tons de cinza.
- **Suavidade** — variação local dos comprimentos do raio.
- **Compacidade** — relação entre perímetro e área.
- **Concavidade** — severidade de porções côncavas do contorno.
- **Pontos côncavos** — quantidade de porções côncavas.

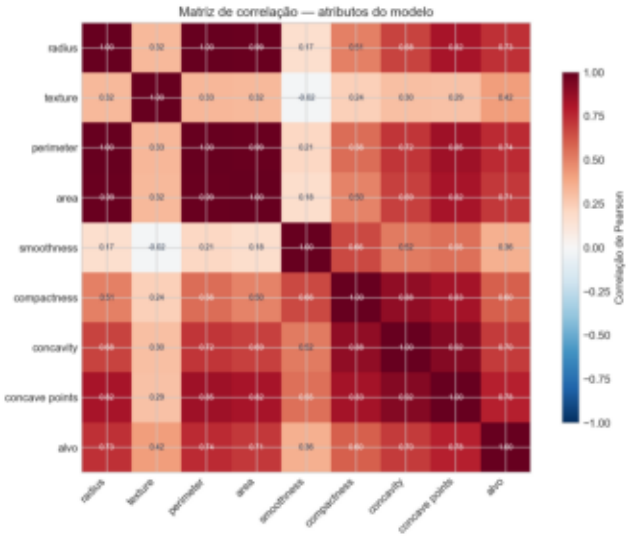
Amostra dos dados

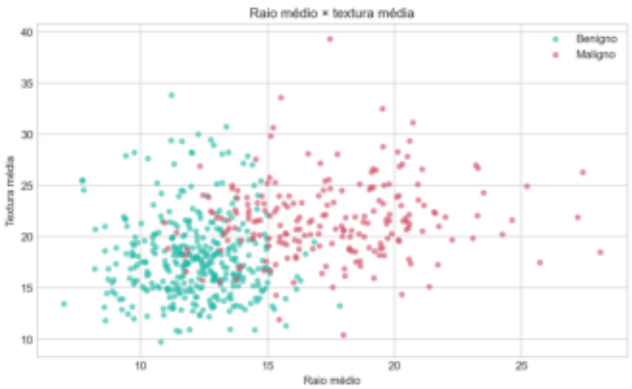
raio	textura	área	concavidade	alvo
17.99	10.38	1001.0	0.3001	1.0
20.57	17.77	1326.0	0.0869	1.0
19.69	21.25	1203.0	0.1974	1.0
11.42	20.38	386.1	0.2414	1.0





- Há desbalanceamento moderado: 62,7% benignos e 37,3% malignos.
- Casos malignos tendem a apresentar raios maiores, mas existe sobreposição.





- Medidas de tamanho são correlacionadas; concavidade e pontos côncavos se associam ao alvo.
- Nenhuma variável isolada separa perfeitamente as classes, justificando um modelo multivariado.

1

Split estratificado

80% treino / 20% teste
random_state = 42

2

Imputação

Mediana ajustada
somente no treino

3

Padronização

StandardScaler dentro
do pipeline

4

Comparação

Regressão Logística × KNN
CV estratificada, 5 folds

5

Teste final

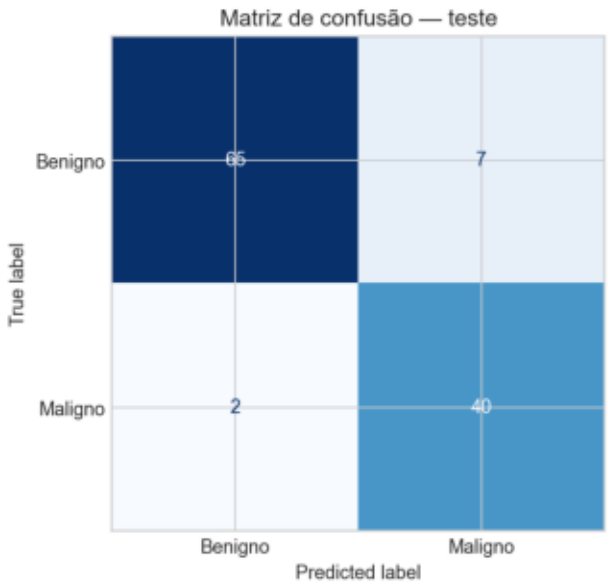
Acurácia, precisão, recall,
F1, matriz e ROC AUC

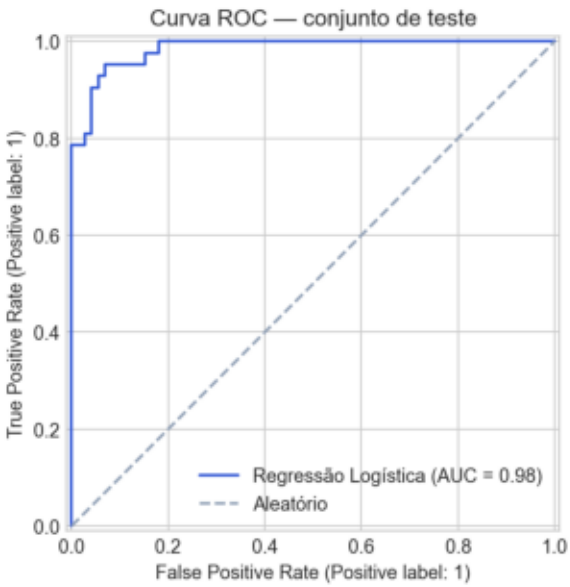
CONTROLE DE VAZAMENTO

Imputador e scaler permanecem dentro de cada pipeline. Assim, cada fold aprende os parâmetros apenas com sua parcela de treino, e o conjunto de teste não participa da escolha do modelo.

Métricas no conjunto de teste

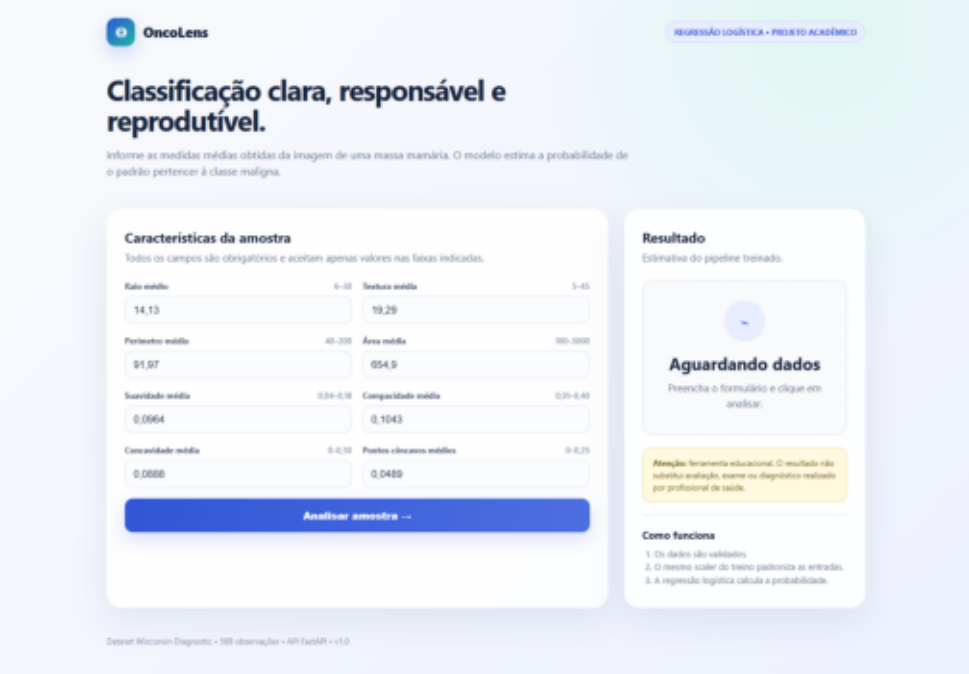
Modelo	Acurácia	Precisão	Recall	F1-Score	ROC AUC
Regressão Logística	0.921	0.851	0.952	0.899	0.984
KNN	0.930	0.905	0.905	0.905	0.986



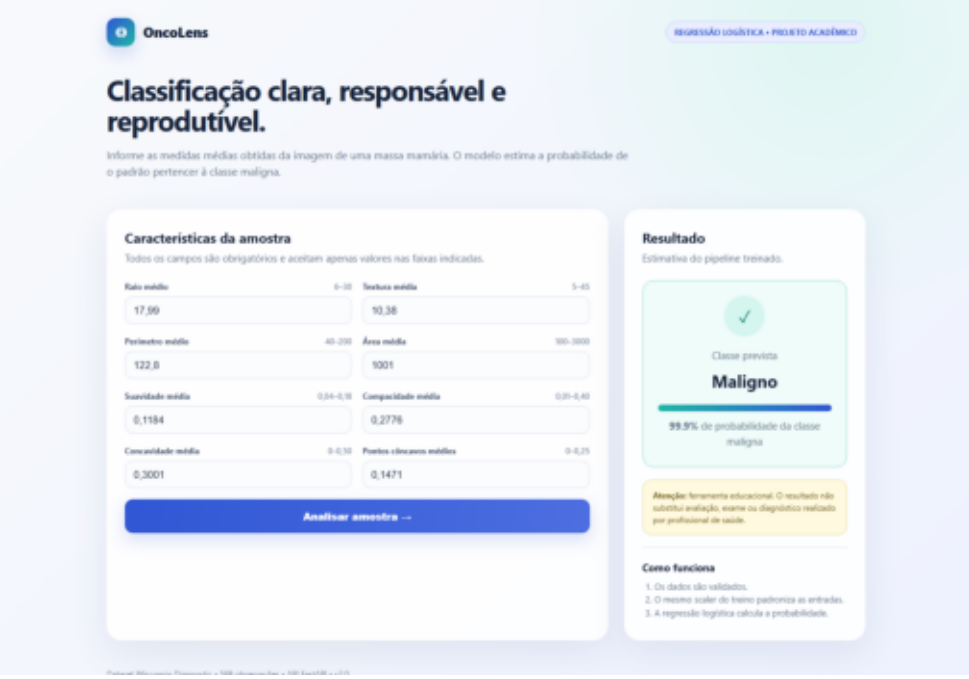


A regressão logística identificou 40 dos 42 casos malignos no teste (recall 95.2%), com 7 falsos positivos e 2 falsos negativos. A seleção foi guiada pelo ROC AUC médio na validação cruzada do treino (0.986), antes de consultar o teste.

Tela principal

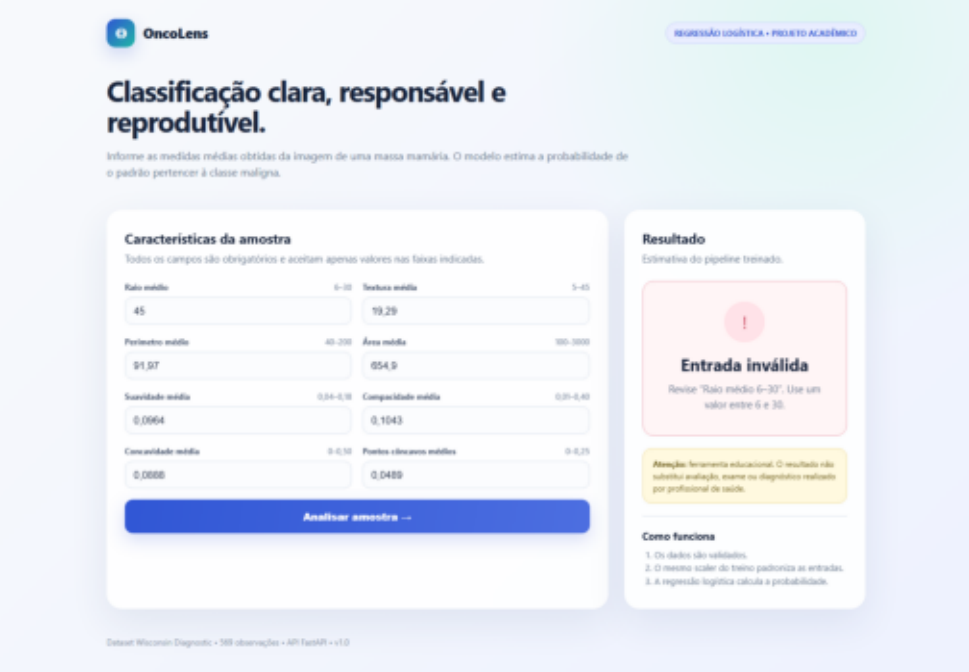


Caso de sucesso: predição válida



A API retorna classe, probabilidade da classe maligna, modelo e aviso de uso responsável.

Caso negativo: valor fora da faixa plausível



O navegador valida campos vazios, tipos e limites. A API repete a validação com Pydantic; portanto, uma chamada direta também recebe HTTP 422 quando os dados são inválidos.

Como executar no PowerShell

```
python -m venv .venv
.\.venv\Scripts\Activate.ps1
pip install -r requirements.txt
uvicorn app:app --reload
```

Depois, acesse http://127.0.0.1:8000. A documentação da API fica em /docs.

1. O ciclo completo foi realizado: inspeção, EDA, pré-processamento, comparação, teste, exportação e interface.

2. A regressão logística apresentou ROC AUC de 0.984 e recall de 0.952 no teste.

3. O pipeline evita vazamento e garante que a mesma padronização seja aplicada na API.

4. A interface torna o resultado compreensível e trata entradas inválidas em duas camadas.

5. A amostra é pequena, antiga e não representa toda a diversidade de populações e equipamentos.

6. Não houve validação externa, calibração clínica nem auditoria de desempenho por subgrupos.

7. Trabalhos futuros devem usar coortes independentes, calibrar o limiar e monitorar drift.

Referências e arquivos

• Wolberg, W. et al. (1993). Breast Cancer Wisconsin (Diagnostic). UCI. DOI: 10.24432/C5DW2B.

• scikit-learn. load_breast_cancer e documentação de Pipeline, LogisticRegression e métricas.

• Artefatos: notebook_ml.ipynb, app.py, static/index.html e models/*.joblib.